

Benchmark report

RAG SaaS Platform

Performance report

Performance — état des preuves au 2026-10-03

Aucun benchmark de production ou PostgreSQL staging effectué. Source historique : [README](#) et [ROADMAP](#).

Mesures de cette mission

- Frontend Vitest, première exécution : 13 fichiers, 112 tests passés,

144.28 secondes, un worker.

- Rejeu après correctifs : 13 fichiers, 112 tests passés, 118.26 secondes.
- Variation observée entre runs, pas amélioration attribuable au correctif :

import/cache/système et environnement jsdom différent.

- Le rapport Vitest relève jsdom créé 13 fois; optimisation éventuelle

doit conserver isolation des tests, pas désactiver isolate sans preuve.

- Ruff backend initial : 3 253 diagnostics; coût/performance API n'en

découle pas.

- Pendant pytest complet, processus principal ~1.36 Go de working set

observé une fois; ce n'est pas un pic mémoire ni une limite garantie.

Limites du retrieval documentées

Le README indique benchmark portable à 100/1 000 documents, pas la route HTTP concurrente ni pgvector/HNSW à 10 000 documents. BM25 calculé par requête sur chunks d'organisation; index full-text persistant planifié.

Latence p50/p95 API, throughput, coût/req, plan SQL live, N+1 sous charge, performance audio et coût RTC : **UNKNOWN** dans cette mission. Pas d'index nouveau ou de refactoring conjectural sans profil.

Prochaine validation

Staging accessible, corpus synthétique représentatif, jobs isolés, providers sandbox/budget, p95 SQL/HTTP, concurrence et tests de fuite tenant. Toute optimisation doit comparer au baseline sur la même machine et

conserver les tests de sécurité.

Limits

No retrieval-quality baseline (Recall@K, MRR, NDCG) has been produced on a real dataset yet; the numbers above, if any, are performance measurements, not answer-quality measurements.